Jozsef Attila poems analysis

Leonardo Toffalini

2026-05-04

Outline

1. Jozsef Attila versek 2
   1.1 Why this matters 3
   1.2 The data 4
   1.3 Elasticsearch 6
   1.4 From data to searchable system 7
   1.5 Elasticsearch in action 8
   1.6 Most common words and phrases 11
   1.7 Trends 14

1. Jozsef Attila versek

1.1 Why this matters

- Text search $\neq$ simple keyword matching
- Literature is ambiguous and contextual
- Same word $\Longrightarrow$ different meanings
- **Goal:** Find meaningful lines, not just one to one matches

Question: How to search poetry in a meaningful manner?

1.2 The data

Dataset Viewer

Auto-converted to Parquet | API | Embed | Duplicate | Data Studio

Split (1)
train · 646 rows

Search this dataset

title string · *lengths* 3 – 59	date string · *lengths* 0 – 26	content string · *lengths* 52 – 8.38k
A bánat	1922. aug.–szept.	A bánat szürke, néma postás, Sovány az arca, szeme kék, Keskeny válláról táska lóg le, Köntöse ócska, meg…
A bátrak	1923. jan. 23./1924. dec.	Ki gyáván várja a halált, Magába zárja azt a föld, Midőn a száj lilára vált S két szeme rémületre tört.…
A betűk sivatagában	1923. márc.	A gót s latin betűk sivatagában, Fáradt diák, virágot keresek. Oly szürke vagyok multban és a mában S…
A boldogság nyitott könyv, tessék, olvassák	1934 [?]	Nem, nem igaz, nem, nem igaz, hogy Ádám volt az első gaz. 'Sz azért nő alma, hogy szakasszon almát a férfi…
A bőr alatt halovány árnyék	1927. jan.	Egy átlátszó oroszlán él fekete falak között, szívemben kivasalt ruhát hordok amikor megszólítlak nem szabad…
A bűn		Zord bűnös vagyok, azt hiszem és jól érzem magam. Csak egy zavar e semmiben: Mi bűnöm van, ha van? A bűn az…

‹ Previous 1 2 3 ... 7 Next ›

Figure 1: József Attila összes - hf.co/tleo/jozsef_attila_osszes

1.2 The data

- Source: scraped from (mek.oszk.hu)
- Preprocessing:
  - Clean formatting
  - Chunked into poems
  - Extracted metadata (title, contents, date)
  - Sanitized dates
- Goals:
  - Search across poems
  - Retrieve lines
  - Extract titles, highlights

1.3 Elasticsearch

- Full-text search engine
- Handles:
  - Tokenization
  - Ranking relevance
  - Fuzzy matching
- Features:
  - Ranked results
  - Highlighting
  - Fast queries

1.4 From data to searchable system

- Convert poems ⟶ documents
- Define fields:
  - title
  - full text
  - lines
  - year (if available)
- Index into Elasticsearch

1.5 Elasticsearch in action

```
query = {
    "multi_match": {
        "query": "Duna",
        "fields": ["title^2", "content"]
    }
}
```

```
[{'score': 5.836489, 'title': 'Népdalok à la Ringelnatz Morgenstern', 'date': '1928.
szept. 30.'},
 {'score': 5.174677, 'title': 'Tavasz van! Gyönyörű!', 'date': '1924 tavasza'},
 {'score': 4.837141, 'title': 'Hajón megyek Pestre','date': '1924 első fele'},
 {'score': 4.278927, 'title': 'A csodaszarvas', 'date': '1933. júl. [?]'},
 {'score': 3.626894, 'title': 'A Dunánál', 'date': '1936. jún.'}]
```

1.5 Elasticsearch in action


```
query = {
    "match_phrase": {
        "content": "A rakodópart alsó kövén ültem"
    }
}
```

```
TITLE: A Dunánál
DATE: 1936. jún.
HIGHLIGHT:
### 1

<em>A</em> <em>rakodópart</em> <em>alsó</em> <em>kövén</em> <em>ültem</em>,
néztem, hogy úszik el a dinnyehéj.
```

1.5 Elasticsearch in action

Keyword search

`Duna` ⟶ searches title + content

Keyword search

- Multiple poems returned
- Ranked by relevance
- Different contexts

Phrase search

`"A rakodópart alsó kövén ültem"` ⟶ exact sequence only

Phrase search

- Exact match found
- Highlighted text
- Shows full context

[...] *rakodópart alsó kövén ültem* [...]

1.6 Most common words and phrases

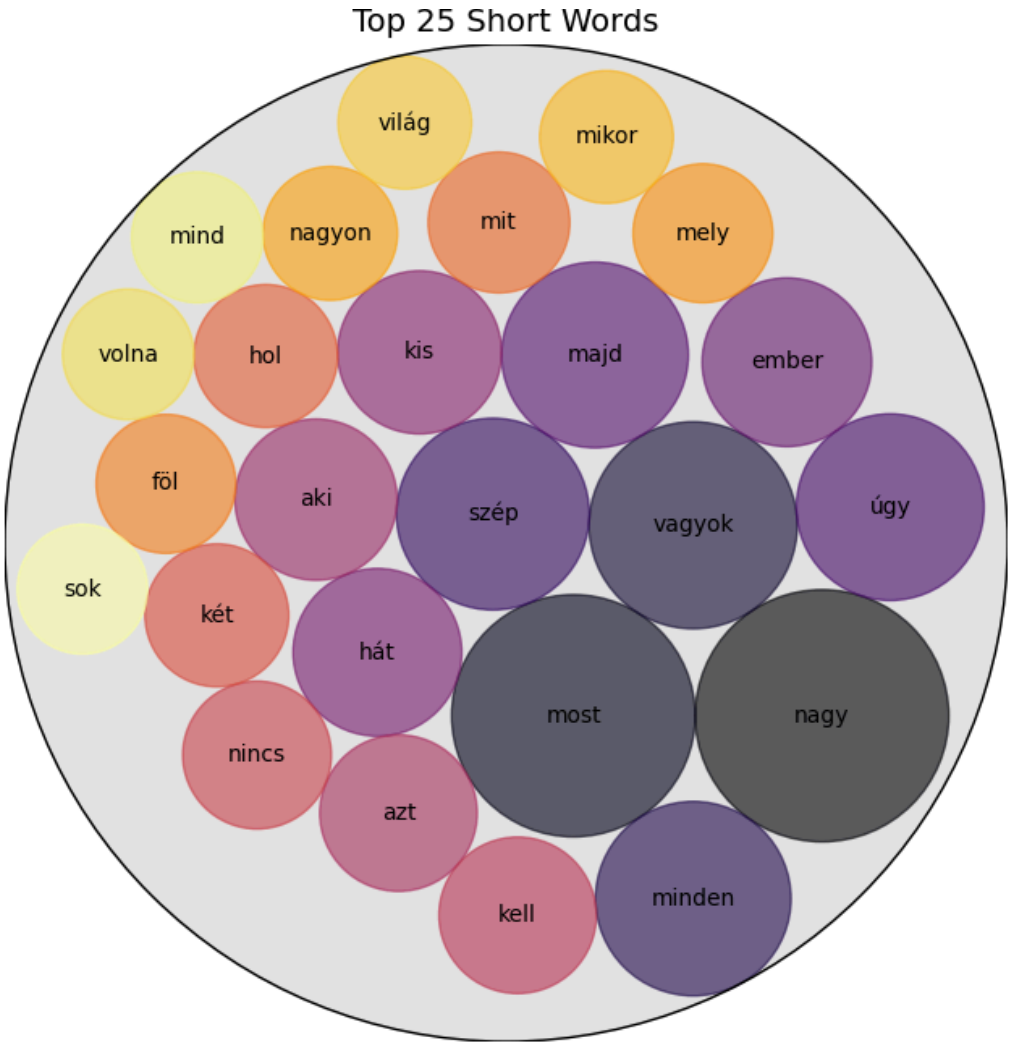

1.6 Most common words and phrases

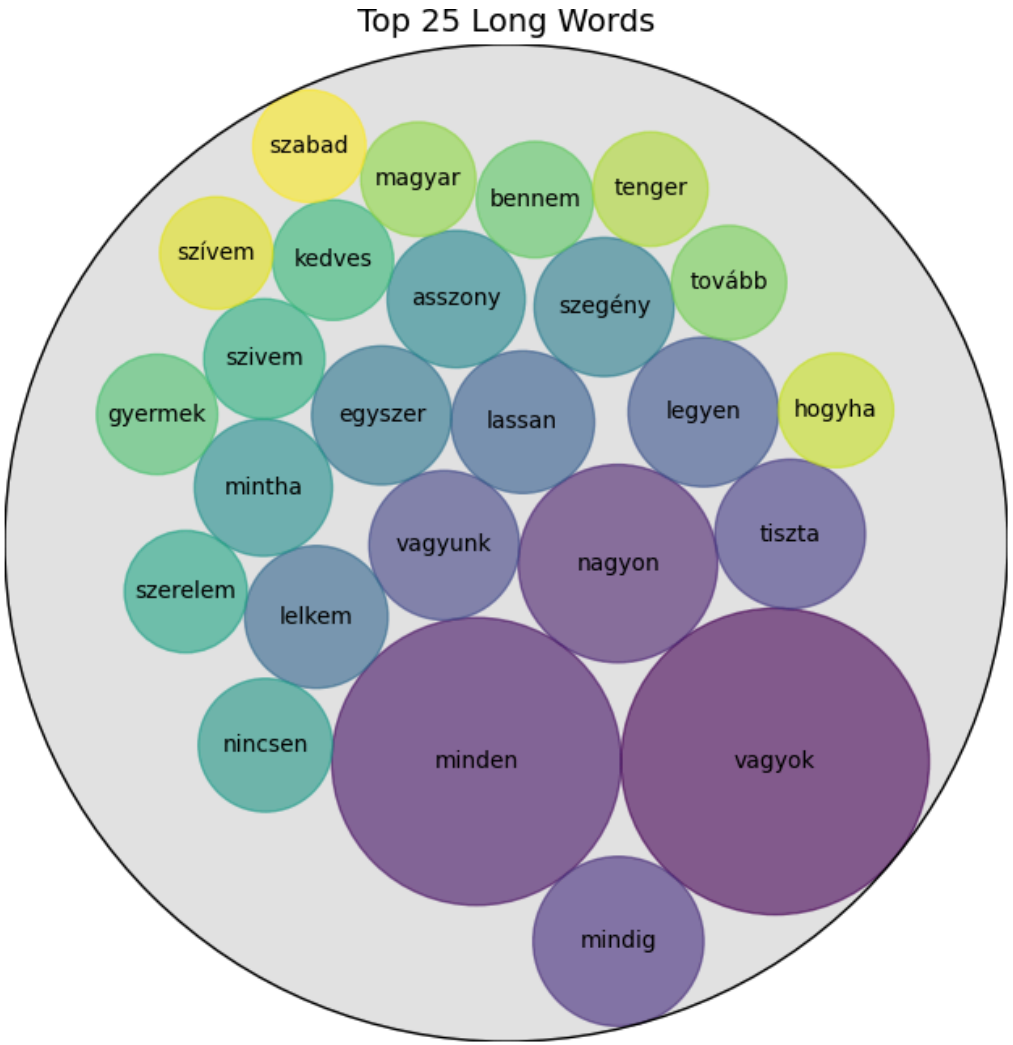

1.6 Most common words and phrases

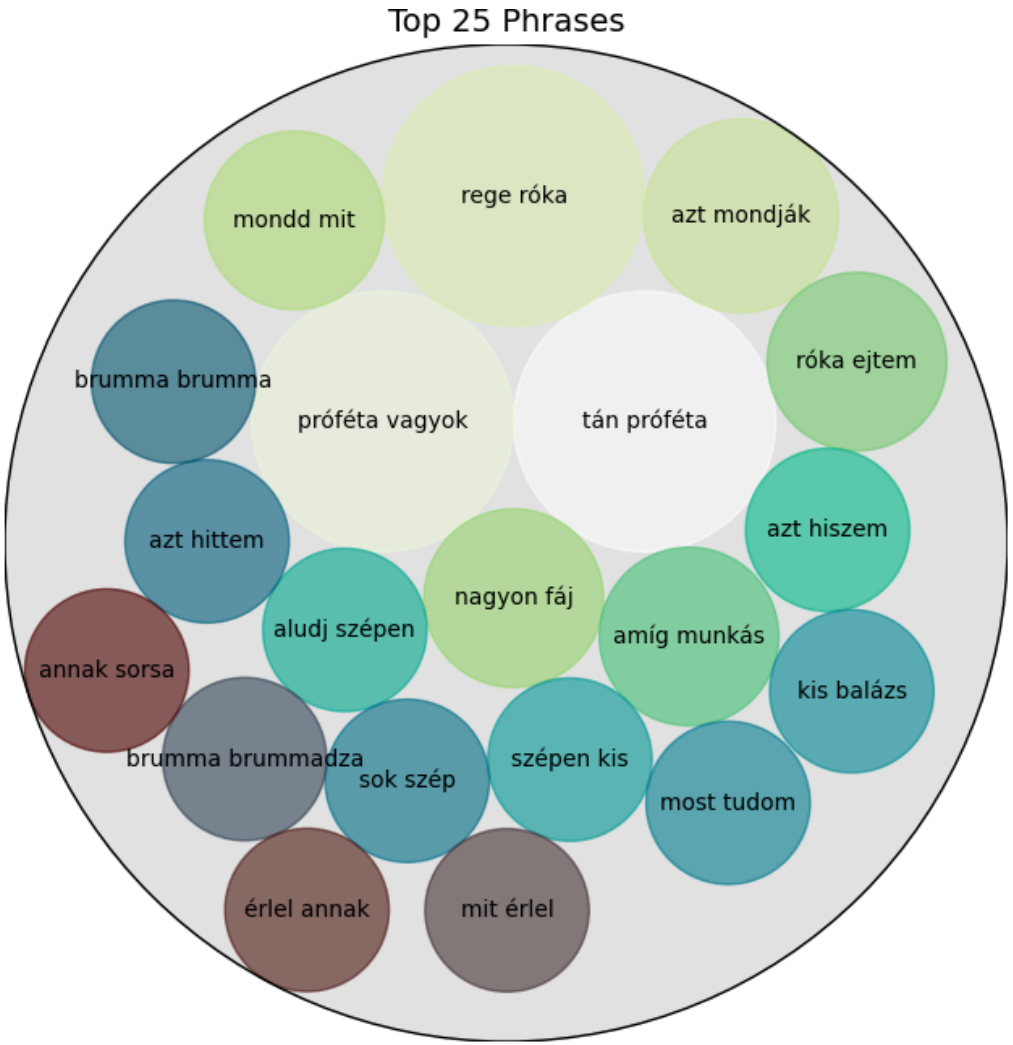

1.7 Trends

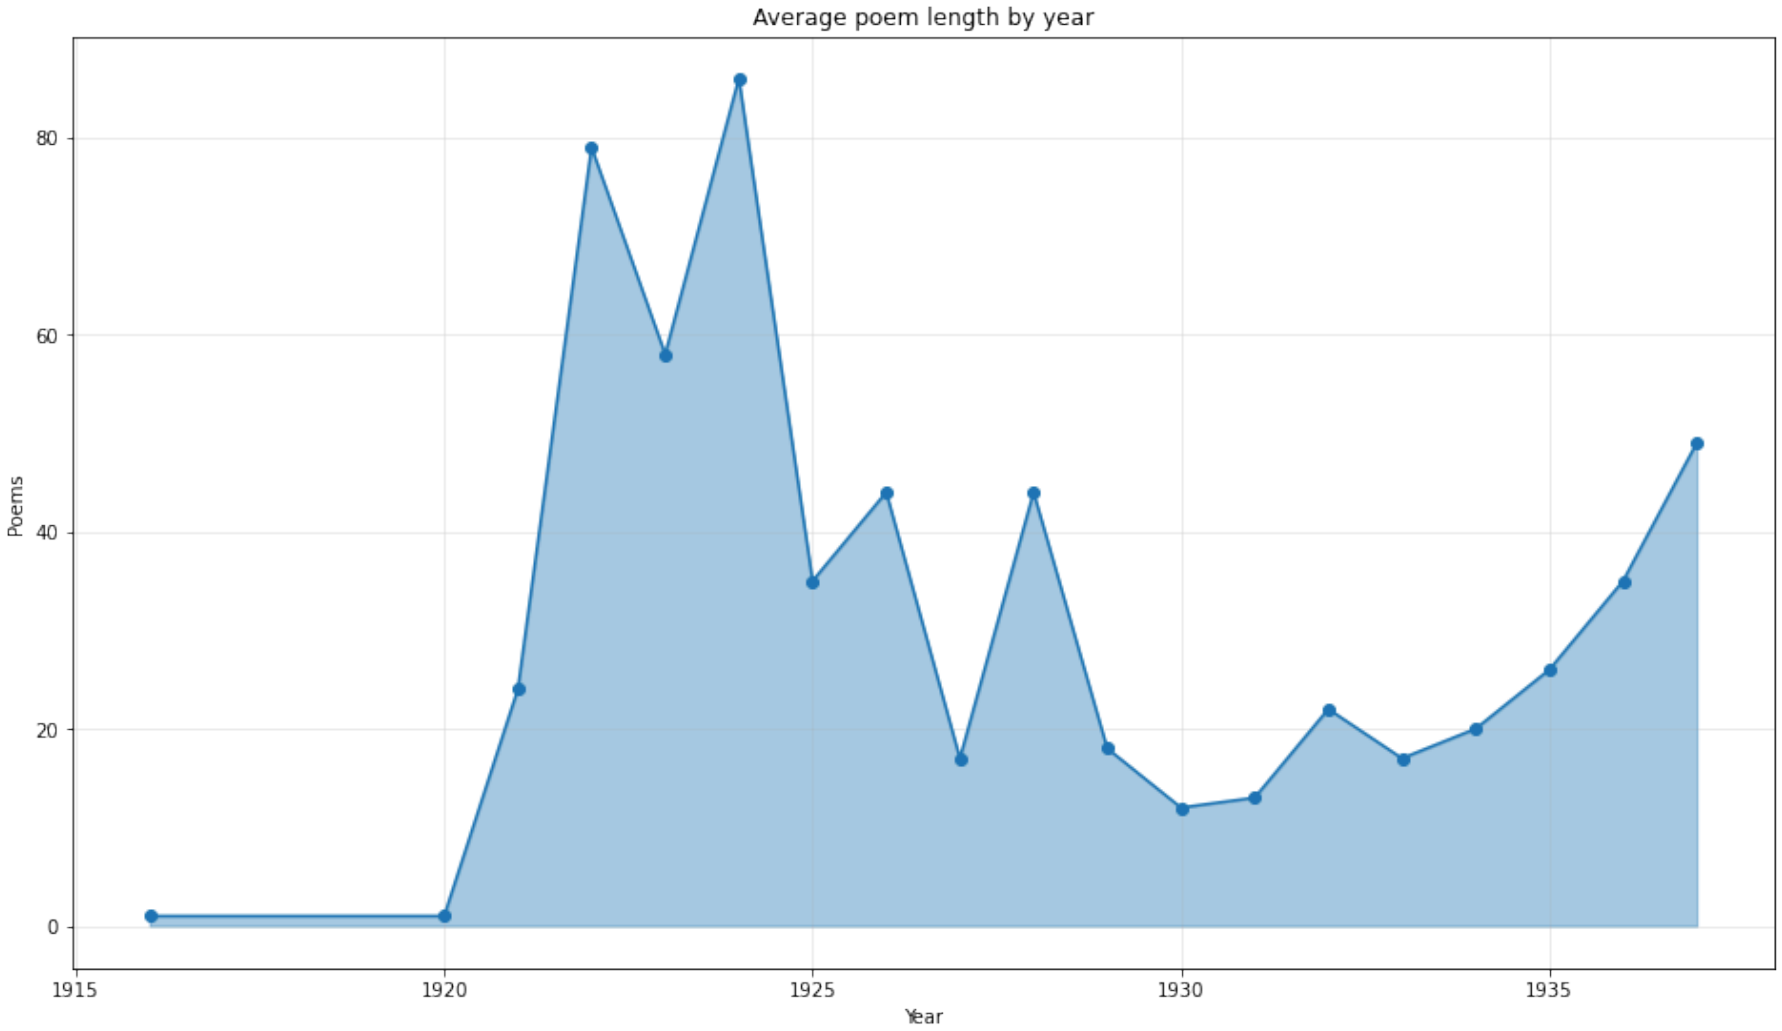
Average poem length by year
Poems
0
20
40
60
80
1915
1920
1925
1930
1935
Year

1.7 Trends

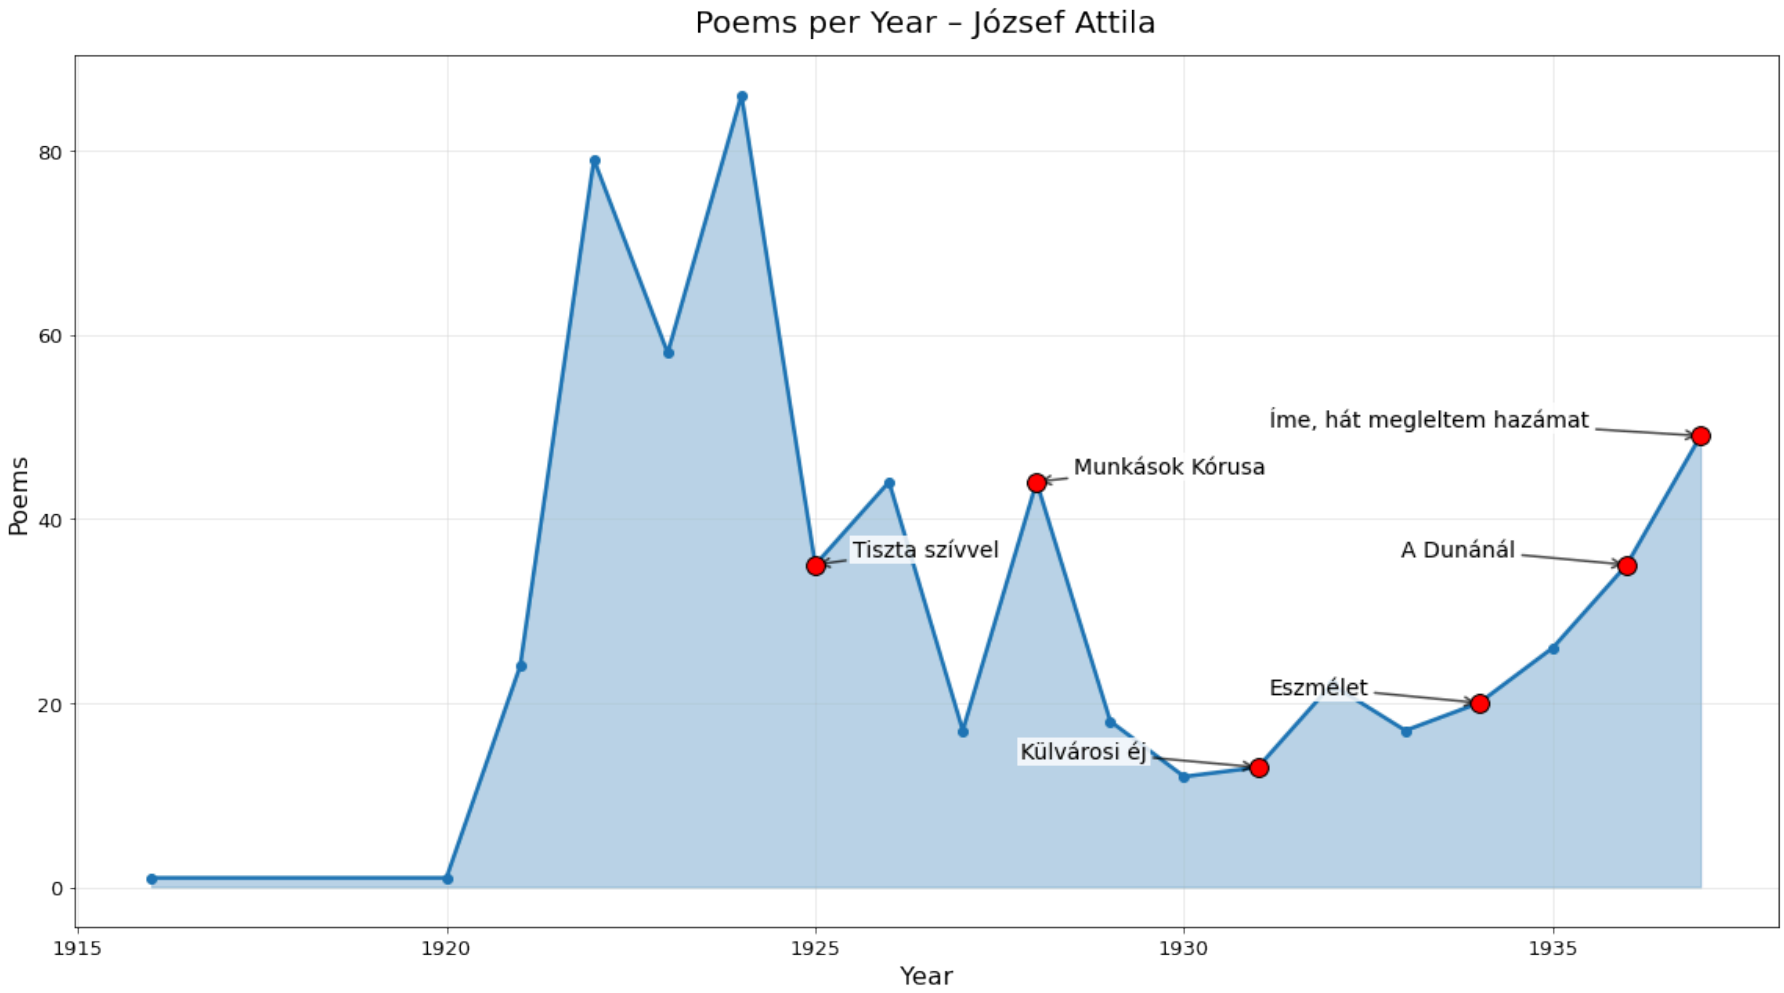
Poems per Year – József Attila
Poems
Year
0
20
40
60
80
1915
1920
1925
1930
1935
Tiszta szívvel
Munkások Kórusa
Külvárosi éj
Eszmélet
A Dunánál
Íme, hát megleltem hazámat

1.7 Trends

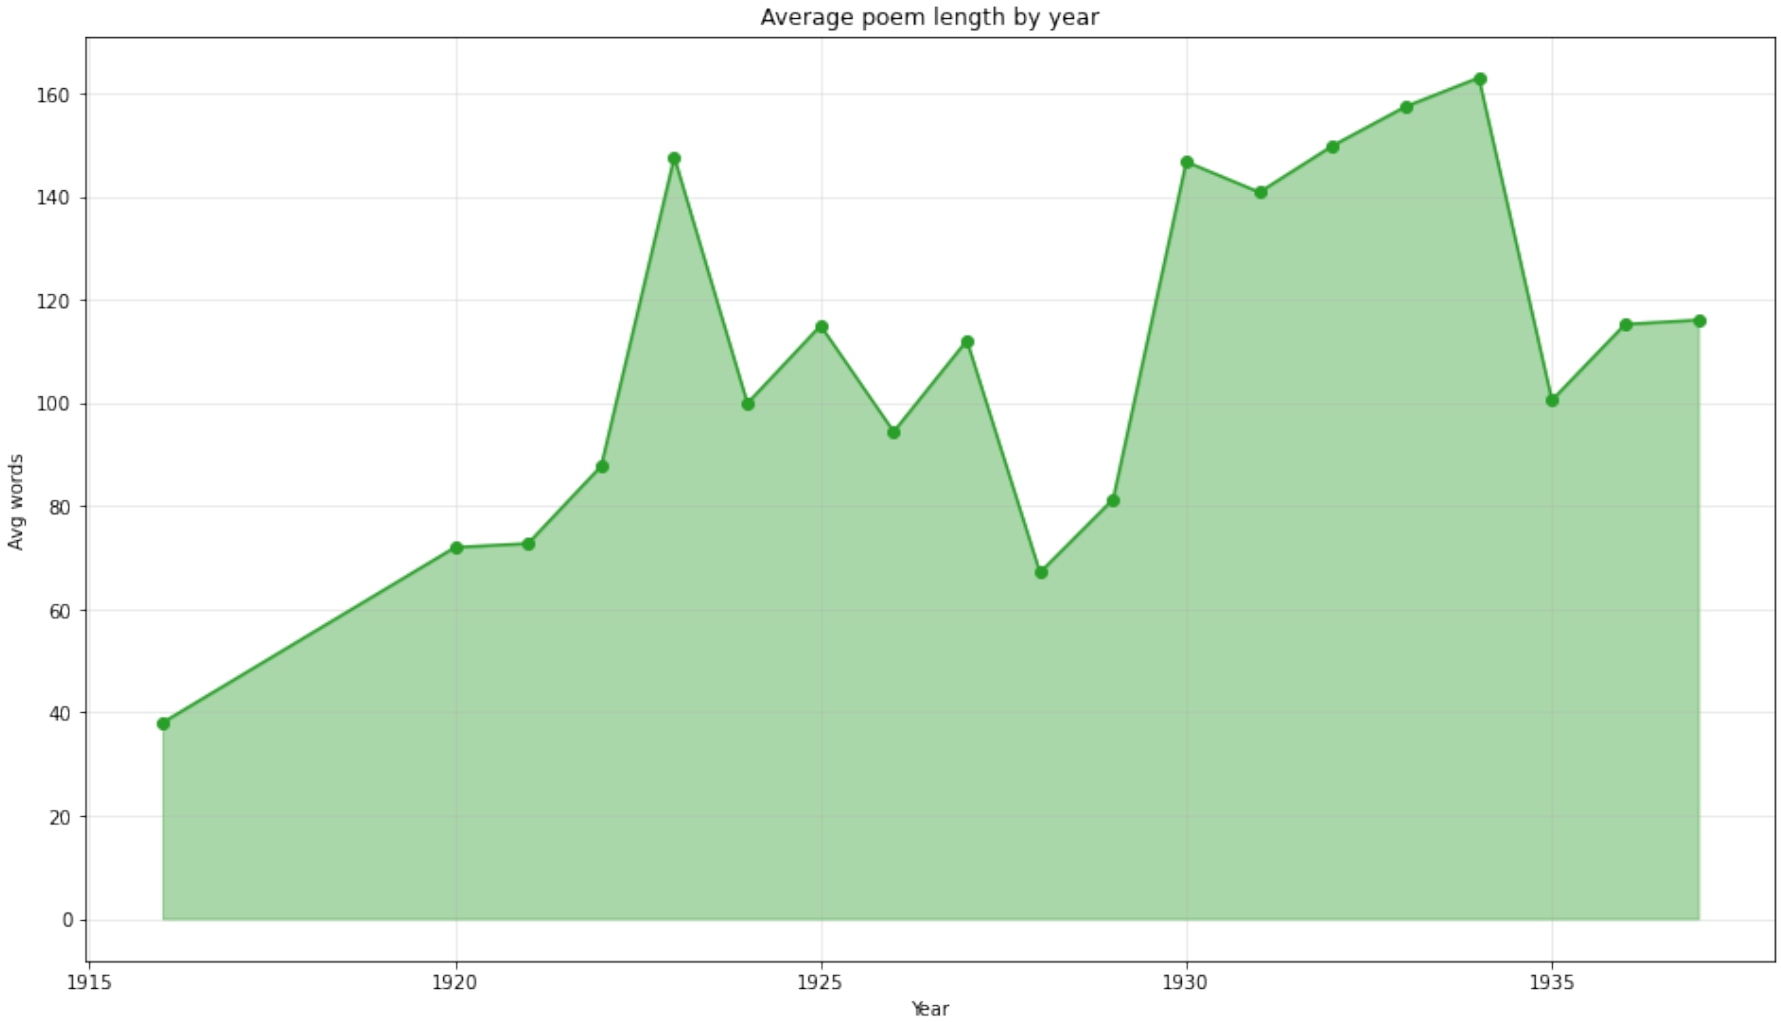
Average poem length by year
Avg words
Year
0
20
40
60
80
100
120
140
160
1915
1920
1925
1930
1935

1.7 Trends

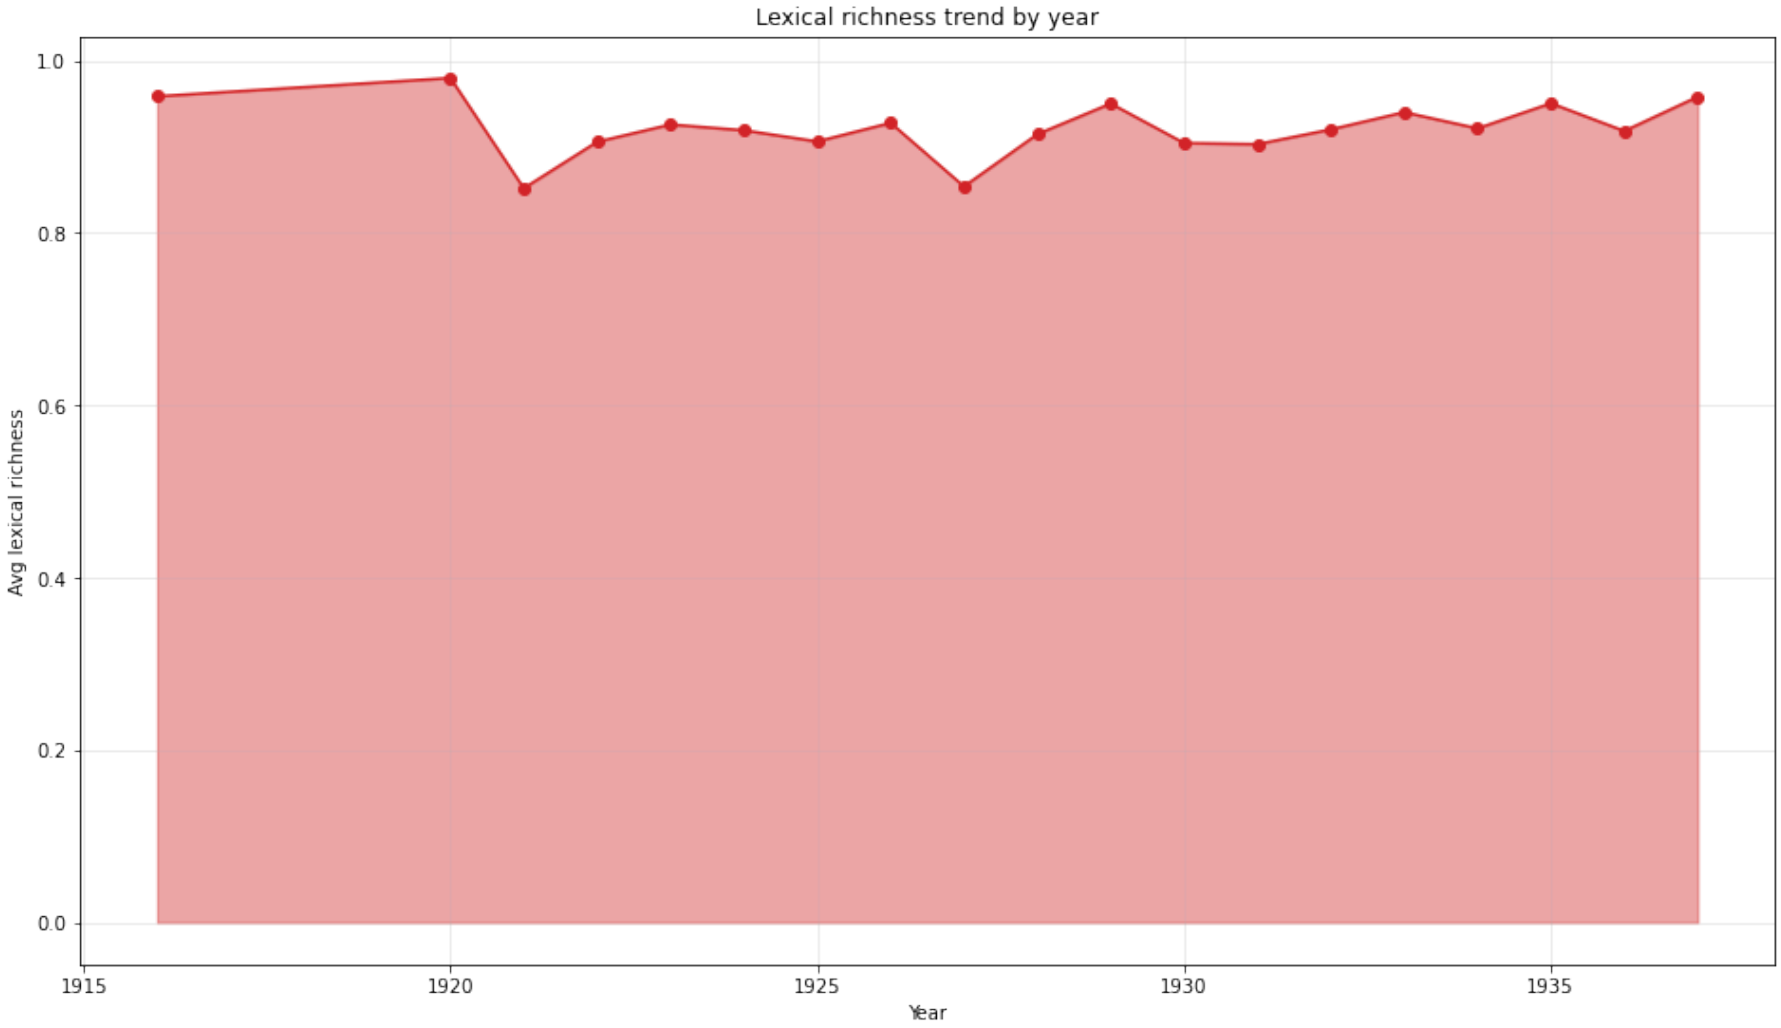
Lexical richness trend by year
Avg lexical richness
1.0
0.8
0.6
0.4
0.2
0.0
1915
1920
1925
1930
1935
Year

1.7 Trends

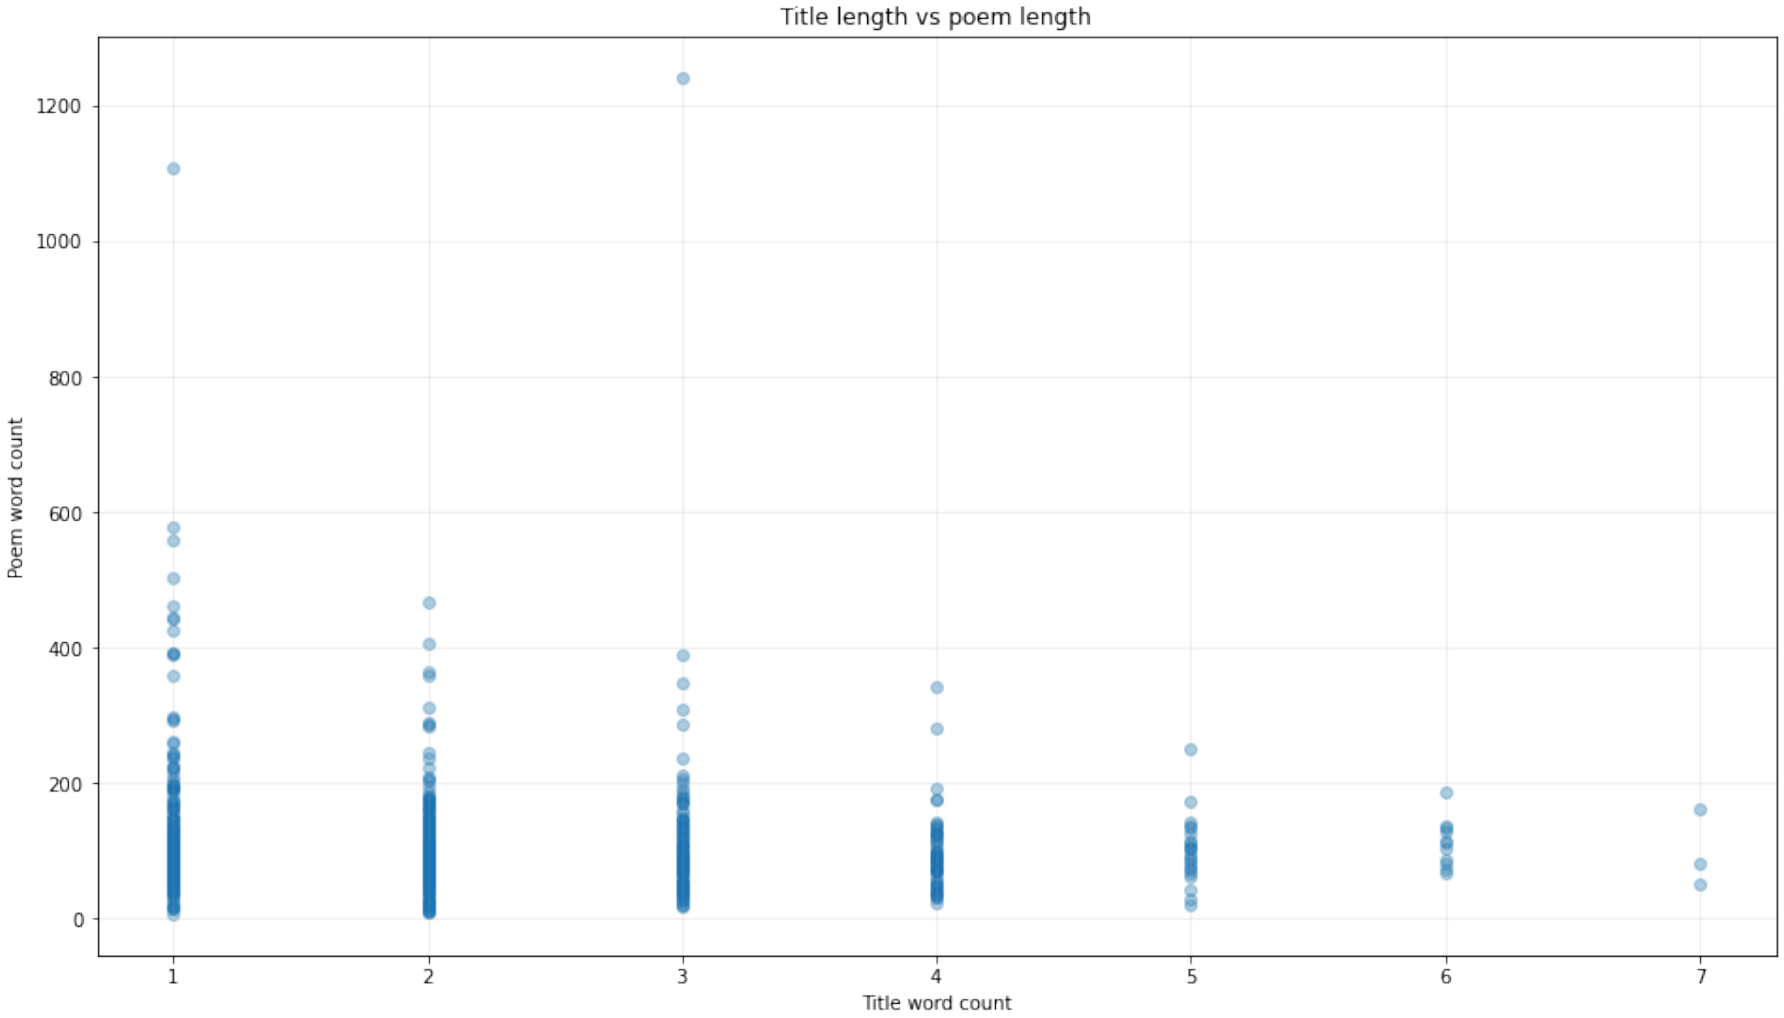
Title length vs poem length
Poem word count
Title word count
0
200
400
600
800
1000
1200
1
2
3
4
5
6
7